

Shortest Common Superstring

Projekat iz predmeta Računarska inteligencija

Ime Prezime XX/20XX

Formulacija problema

- Za dati konačan skup stringova $S = \{s_1, \dots, s_n\}$, potrebno je pronaći najkraći string T takav da se svaki s_i pojavljuje kao podstring od T .
- Intuitivno: pronaći najkraći string koji sadrži sve zadate stringove.
- SCS je NP-težak problem (Gallant et al., 1980).

Kodiranje ulaznih podataka i rešenja

- Kodiranje rešenja: lista vrednosti 0 i 1 dužine $|S|$
 - i -ti element određuje da li je i -ti string iz S deo superstringa
- Matrica pokrivenosti T dimenzije $|S| \times |S|$
 - Element na poziciji $(i, j) = 1$ ako $s_j \subseteq s_i$ (s_j je podstring od s_i)
- Vektor težina w — $w_j =$ broj stringova koji pokrivaju s_j

Funkcija cilja

- Leksikografski uređen par: (broj_nepokrivenih, dužina_superstringa)
- Manji fitness je bolji — prioritet: što manje nepokrivenih stringova, a zatim što kraći superstring
- Težinska varijanta: penalizacija = $\sum 1/(w_j + 1)$ za nepokrivene s_j
 - Stringovi koji se teže pokrivaju dobijaju veću penalizaciju

Implementirani algoritmi

Algoritam	Tip	Skalabilnost
Brute Force	Egzaktni	male ($ S \leq 20$)
MILP (CPLEX)	Egzaktni	male / srednje
Greedy	Aproksimativni	sve veličine
Genetic Algorithm	Metaheuristika	sve veličine
VNS	Metaheuristika	sve veličine
VNS Weighted	Metaheuristika	sve veličine

Genetski algoritam

- Kodiranje: binarna lista dužine $|S|$
- Selekcija: turnirska selekcija
- Ukrštanje: uniformno (svaki gen nezavisno bira roditelja)
- Mutacija: bit-flip sa verovatnoćom p_m po genu
- Elitizam: top $e\%$ jedinki direktno prelazi u novu generaciju

Metoda promenljivih okolina (VNS)

- Shaking: k nasumičnih swap operacija (perturbacija rešenja)
- Lokalna pretraga: bit-flip first-improvement
- k raste od k_min do k_max kroz strukturu susedstava
- VNS Weighted koristi ponderisanu funkciju cilja
 - Usmerava pretragu ka teže pokrивljivim stringovima

Rezultati – male instance

Algoritam	% feasible	% optimalnih	Prosečno vreme
bruteForce	100%	100%	~0.20 s
milp	100%	100%	~0.025 s
greedy	100%	93.3%	< 0.001 s
genetic	100%	96.7%	~0.08 s
vns	100%	100%	~0.012 s
vnsWeighted	100%	100%	~0.008 s

Zaključak

- Greedy je najbrži, ali ne garantuje optimum (93.3% optimalnih)
- VNS i VNS Weighted postižu 100% optimalnih na malim instancama
- GA zahteva podešavanje parametara po skali, ali daje dobre rezultate
- MILP je egzaktn, ali ne skalira na velike instance
- Moguća poboljšanja: bitmask DP, hibridni GA+VNS, realni genomski podaci